

Segmentación Retórica y Detección de Contribuciones en Artículos Científicos en Español: Un Enfoque Comparativo entre Encoders Especializados y Grandes Modelos de Lenguaje

Grupo 2 · Proyecto de Grado en Procesamiento de Lenguaje Natural · MAIA 2026

Cristian Alexis Murillo Martínez · Edwin Alexander Cifuentes Bastidas · Juan Pablo Pérez Atehortúa · Natalia Moncada Suárez · Santiago Ballesteros Pastrán

Grupo de Investigación FLAG – TICsW · Departamento de Ingeniería de Sistemas y Computación · Universidad de los Andes, Bogotá, Colombia

Asesor: Rubén Manrique, Ph.D.

Resumen

La gestión de la creciente producción científica en español se ve limitada por la ausencia de metadatos estructurales consistentes en los documentos académicos. Este artículo presenta un sistema automatizado para la estructuración de textos científicos mediante dos tareas complementarias: (1) segmentación y clasificación retórica en siete categorías funcionales —Introducción (INTRO), Antecedentes (BACK), Metodología (METH), Resultados (RES), Discusión (DISC), Limitaciones (LIM) y Conclusiones (CONC)— y (2) detección binaria de contribuciones científicas originales. Bajo un enfoque de Inteligencia Artificial centrada en los datos (Data-Centric AI), se evaluó el desempeño del encoder especializado SciBETO-large, ajustado mediante fine-tuning supervisado, frente a las capacidades zero-shot y few-shot de grandes modelos de lenguaje (LLMs): Llama 3.1 8B-Instruct y GPT-4o-mini.

En la Tarea 1, el modelo GPT-4o-mini lideró el desempeño con un $f1_macro$ de 0.447 usando una estrategia *zero-shot*, seguido por SciBETO-large con un F1 Macro de 0.4, mientras que Llama 3.1 8B-Instruct alcanzó un máximo de 0.322 mediante few-shot prompting. En la Tarea 2, SciBETO-large texto puro logró F1 Macro = 0.8523 (IC 95%: [0.79, 0.90]) sobre un Gold Test Set de 170 fragmentos con acuerdo interanotador $\kappa = 0.6995$, frente a F1 Macro = 0.3930 de Llama y 0.4230 de GPT. Un hallazgo sorpresivo en la detección binaria de contribuciones es que la incorporación del contexto retórico como prefijo textual deteriora el desempeño de SciBETO ($\Delta = -0.044$), dado que las contribuciones se distribuyen de forma mixta entre secciones. El estudio demuestra que la estrategia de curaduría de datos y la alineación de la ventana de atención son tan determinantes como la elección de arquitectura.

Palabras clave: Procesamiento de Lenguaje Natural, Segmentación Retórica, Extracción de Contribuciones Científicas, SciBETO, Grandes Modelos de Lenguaje, Español Científico, Data-Centric AI, Silver Labels, Fine-tuning.

1. Introducción

El crecimiento exponencial de la producción científica global ha transformado la gestión del conocimiento en un desafío de procesamiento masivo de información. Se estima que más de 2 millones de artículos científicos se publican anualmente, lo que hace inviable la revisión manual sistemática de la literatura [1]. En este contexto, el Procesamiento de Lenguaje Natural (PLN) ha facilitado herramientas para la indexación, el resumen automático y la clasificación de documentos. No obstante, la gran mayoría de estos avances han sido diseñados y optimizados para el inglés, dejando una brecha significativa para la literatura científica en otros idiomas, en particular el español.

El español es uno de los idiomas más utilizados en la comunicación académica, especialmente en tesis de grado, informes técnicos y revistas regionales de Iberoamérica. A pesar de su relevancia, los documentos científicos en español carecen frecuentemente de metadatos estructurales consistentes que permitan una navegación ágil por su contenido. La escritura académica en español presenta desafíos particulares respecto al inglés: mayor variabilidad estructural entre tipos de documentos, convenciones retóricas dependientes del dominio disciplinar, sintaxis más compleja y extensión de oraciones más elevada, lo que dificulta la transferencia directa de modelos pre-entrenados en inglés sin degradación de rendimiento.

Este trabajo aborda dicha problemática mediante un sistema de análisis dual que estructura automáticamente artículos científicos en español a través de dos tareas complementarias. La Tarea 1 implementa la segmentación y clasificación retórica: identificar la función discursiva de cada fragmento textual (introducción, antecedentes, metodología, resultados, discusión, limitaciones, conclusiones). La Tarea 2 implementa la detección de contribuciones científicas: identificar de forma binaria si un fragmento textual contiene o no un aporte original del autor. Al separar las contribuciones como propiedad transversal —en lugar de incluirlas como una octava categoría retórica mutuamente excluyente— el sistema captura con mayor fidelidad la naturaleza del discurso académico, donde un aporte puede coexistir simultáneamente con otras funciones retóricas.

Los objetivos principales son: (i) desarrollar un clasificador retórico de 7 categorías para español científico; (ii) implementar un clasificador binario transversal para la identificación de contribuciones científicas; (iii) realizar un estudio comparativo riguroso entre encoders especializados (SciBETO-large) y LLMs (Llama 3.1 8B-Instruct, GPT-4o-mini) bajo condiciones equiparables; y (iv) desplegar un demostrador interactivo que integre ambos modelos. La contribución diferencial reside en demostrar empíricamente, mediante un enfoque *Data-Centric AI*, que la estrategia de curaduría de datos y la gestión de la ventana de contexto son tan determinantes como la elección de arquitectura para el análisis automático del discurso científico en español.

2. Estado del Arte

2.1. Modelos de Lenguaje en el Dominio Científico

El paradigma del PLN fue transformado radicalmente por la arquitectura Transformer y el modelo BERT [2], cuyas capacidades de comprensión contextual bidireccional marcaron un punto de inflexión. La limitación de BERT ante vocabulario técnico científico motivó el surgimiento de SciBERT [3], entrenado en un corpus masivo de artículos académicos en inglés procedentes de Semantic Scholar. SciBERT demostró que el pre-entrenamiento en un dominio específico supera consistentemente a los modelos genéricos en tareas de minería de textos científicos: extracción de entidades nombradas, clasificación de relaciones y reconocimiento de afirmaciones científicas.

2.2. Recursos para el Español Académico y SciBETO

Para el español, el desarrollo de modelos de lenguaje comenzó con BETO [4], una implementación de BERT pre-entrenada sobre Wikipedia en español. Sin embargo, al igual que ocurrió en inglés con la distinción BERT/SciBERT, el español académico requería especialización léxica adicional. En respuesta a esta necesidad, el grupo de investigación FLAG de la Universidad de los Andes desarrolló SciBETO-large [5], arquitectura basada en RoBERTa optimizada específicamente para el dominio científico en español, incorporando un vocabulario técnico especializado construido a partir de tesis, artículos de revistas iberoamericanas y reportes técnicos. Este modelo constituye el estado del arte actual para tareas de clasificación de texto en el nicho del español científico.

2.3. Segmentación Retórica del Discurso Científico

La segmentación retórica de textos científicos se fundamenta en la teoría de los movimientos retóricos propuesta por Swales [6], quien define unidades textuales con propósito comunicativo específico dentro de la estructura del artículo académico. En inglés existen recursos consolidados como PubMed-RCT (200.000 frases anotadas de abstracts biomédicos) y NICTA-PIBOSO para este fin. Para español, la disponibilidad de corpus anotados es notablemente inferior. Investigaciones previas han aplicado reglas heurísticas y clasificadores de características superficiales, pero solo con el auge de los modelos de encoder pre-entrenados se ha logrado automatizar la detección de secciones con una precisión aceptable para aplicaciones de gran escala.

2.4. LLMs y Razonamiento Zero-Shot/Few-Shot

La aparición de los modelos de lenguaje de gran escala, como la familia Llama 3 [7] y las iteraciones de GPT [8], introdujo la posibilidad de inferencia sin entrenamiento específico (zero-shot). Gracias a su vasto conocimiento paramétrico, estos modelos han demostrado capacidad para interpretar funciones retóricas basándose exclusivamente en instrucciones textuales. Sin embargo, estudios recientes evidencian que, aunque los LLMs son versátiles, los encoders ajustados mediante fine-tuning mantienen una ventaja competitiva en términos de especificidad, eficiencia computacional y estabilidad de predicciones para tareas de clasificación multiclase en idiomas distintos del inglés y dominio especializado.

2.5. Brecha en la Literatura

A pesar de los avances mencionados, persiste una brecha crítica: la ausencia de estudios comparativos que evalúen el impacto de la calidad y la longitud de los fragmentos del dataset (la perspectiva Data-Centric) sobre el análisis retórico en español. La mayoría de los trabajos se centran en la selección de arquitectura, ignorando cómo la estrategia de etiquetado automático (Silver Labels) y la alineación de la ventana de contexto entre entrenamiento y evaluación afectan el rendimiento real del sistema. Este proyecto aborda dicha brecha de forma sistemática.

3. Metodología

El desarrollo del proyecto se fundamentó en un enfoque híbrido Data-Centric AI y centrado en el modelo, con especial énfasis en la comprensión de la señal textual y la resolución de solapamientos semánticos. A diferencia de los enfoques convencionales que priorizan únicamente la optimización de hiperparámetros, esta metodología dedicó esfuerzo sistemático a la curación iterativa de los datos de entrenamiento y evaluación.

3.1. Corpus Base y Preprocesamiento

El corpus de partida fue provisto por el grupo FLAG, consistente en 1.812.557 documentos académicos en español procesados como texto plano (.txt) extraídos de CORE mediante su API. El corpus incluye artículos científicos, tesis de grado y reportes técnicos provenientes de múltiples dominios disciplinares y fuentes institucionales iberoamericanas. El pipeline de preprocesamiento implementó cuatro etapas secuenciales: (i) filtrado estructural mediante detección de anclas semánticas ('resumen', 'introducción', 'referencias') para descartar documentos sin estructura académica reconocible (entrevistas, blogs, reportes informales); (ii) normalización textual consistente en la eliminación de ruido propio de la extracción de PDFs: fórmulas matemáticas rotas, caracteres de control, metadatos institucionales, tablas fragmentadas; (iii) neutralización de entidades para garantizar la invarianza del modelo respecto a autores e instituciones; y (iv) segmentación en fragmentos continuos de 250–1.000 palabras aplicando heurísticas de encabezado, posición relativa dentro del documento y patrones léxicos.

3.2. Tarea 1 – Construcción del Dataset Retórico

La Tarea 1 se formuló como clasificación de 7 clases funcionales, excluyendo la clase CONTR que fue separada como Tarea 2 independiente, decisión motivada por el análisis exploratorio que reveló alta colinealidad entre CONTR y múltiples secciones retóricas. Se diseñó un motor de etiquetado automático basado en expresiones regulares de alta precisión y vocabularios controlados por expertos del dominio, generando un corpus de 27.115 fragmentos de entrenamiento como Silver Labels. Adicionalmente, se implementó un paso de desacoplamiento que eliminó los marcadores de sección del texto de entrada (términos como 'Metodología', 'Introducción', 'Estado del Arte'), obligando al modelo a aprender de la semántica del contenido y no de las señales usadas en la construcción del dataset. El conjunto Gold de evaluación consistió en 1.400 fragmentos validados manualmente con doble anotación, respetando estrictamente el criterio de no solapamiento a nivel de documento entre particiones. Para garantizar la confiabilidad y reproducibilidad de este estándar de referencia, se evaluó el acuerdo interanotador mediante los coeficientes de Cohen's $\kappa = 0.671$, Krippendorff's $\alpha = 0.671$, y 71% de acuerdo simple. Estos valores sitúan el consenso en un grado de acuerdo sustancial según las escalas métricas estándar de la literatura, reflejando simultáneamente la

complejidad inherente al delimitar fronteras retóricas sutiles, como la transición entre INTRO y METH, o la existente entre DISC y CONC.

3.3. Tarea 2 – Construcción del Dataset de Contribuciones

Los fragmentos positivos (ES_CONTRIBUCIÓN) se identificaron mediante patrones lingüísticos recurrentes en el español académico: 'este trabajo propone', 'se presenta un nuevo método', 'los resultados demuestran que', 'se introduce un marco comparativo', 'la principal contribución es', entre otros. Estos patrones se enriquecieron con la etiqueta retórica de la Tarea 1, considerando que las contribuciones suelen concentrarse en INTRO, CONC y DISC. Los fragmentos negativos (250–500 palabras) se extrajeron de secciones de antecedentes, metodología estándar y resultados descriptivos sin novedad.

El corpus final constó de 1.600 fragmentos de entrenamiento (794/806 positivos/negativos) y 400 de validación (206/194), todos como Silver Labels. Para el desacoplamiento, en una fracción controlada de fragmentos positivos las expresiones marcadoras fueron enmascaradas o parafraseadas; adicionalmente se introdujeron negativos difíciles con expresiones similares a los patrones de selección, pero sin contribución científica real, para evitar que el clasificador aprenda señales superficiales.

El conjunto Gold de evaluación (200 fragmentos anotados manualmente) se sometió a doble anotación independiente, resultando en Cohen's $\kappa = 0.6995$, Krippendorff's $\alpha = 0.6995$ y 85.0% de acuerdo simple. Los 170 fragmentos con consenso constituyen el Gold Test Set oficial (81 positivos / 89 negativos). Los 30 fragmentos sin acuerdo se reservan exclusivamente para análisis cualitativo. Se evaluaron seis configuraciones: (1) **SciBETO text-only** (baseline, texto crudo sin contexto); (2) **SciBETO + contexto** (prefijo [SECCION:X] [POS:Y] con la etiqueta T1 predicha y la posición relativa); (3-4) **Llama 3.1 8B** zero-shot y few-shot ($k=4$); (5-6) **GPT-4o-mini** zero-shot y few-shot ($k=4$).

3.4. Configuración de Modelos

Se compararon tres paradigmas arquitectónicos: SciBETO-large, Llama3.1, y GPT-4o-mini. SciBETO-large se ajustó mediante fine-tuning supervisado con los siguientes hiperparámetros: 4 épocas, $lr=1e-5$, batch_size=8, weight_decay=0.01, warmup_ratio=0.10, early stopping con patience=2, optimizador AdamW, FP16 habilitado. Para Tarea 2 el umbral de decisión se calibró mediante barrido en [0.30–0.70] (paso 0.025) sobre el conjunto de validación, seleccionando el valor que maximiza el F1 Macro. Además, se evaluaron dos variantes: texto puro (PlainTextDataset) y texto con prefijo de contexto retórico [SECCION:X][POS:Y] (ContextDataset), donde $Y = \text{round}(\text{posición_relativa} \times 10)/10$.

La Tabla 1 consolida los hiperparámetros de fine-tuning de SciBETO-large para ambas tareas. Las principales diferencias son la tasa de aprendizaje (2×10^{-5} en T1 vs. 1×10^{-5} en T2) y el batch size (16 vs. 8), ajustados mediante experimentos preliminares del equipo para maximizar el F1 Macro en validación.

Tabla 1. Hiperparámetros de fine-tuning de SciBETO-large para Tarea 1 y Tarea 2.

Hiperparámetro	Tarea 1 (SciBETO)	Tarea 2 (SciBETO)
Modelo base	SciBETO-large (RoBERTa)	SciBETO-large (RoBERTa)
Batch size	16	8
Learning rate	2×10^{-5}	1×10^{-5}
Épocas máximas	4	4
Early stopping (pac.)	2 épocas	2 épocas
Weight decay	0.01	0.01
Warmup ratio	0.10	0.10
Tokens máximos	512	512
Precisión numérica	bf16	fp16/bf16
GPU	NVIDIA A100-SXM4-80GB	NVIDIA A100-SXM4-80GB
Métrica de evaluación	F1 Macro	F1 Macro

Llama 3.1 8B-Instruct se empleó en modo inferencia pura (zero-shot y few-shot $k=4$) sin fine-tuning adicional, cuantizado a 4 bits NF4 en GPU NVIDIA A100-SXM4-40GB (~14.25 GB VRAM), decodificación greedy (`max_new_tokens=8`). GPT-4o-mini se consumió vía API de OpenAI con `temperatura=0.0`, `max_tokens=8` y hasta 3 intentos con retroceso exponencial ante fallos de API. Para el modo few-shot ($k=4$ y $k=8$), los ejemplos se seleccionaron del conjunto de entrenamiento (sin filtración hacia el test) y se ordenaron de forma alternada (positivo-negativo-positivo-negativo) para mitigar el sesgo posicional.

3.5. Arquitectura del Sistema y Despliegue

La solución final se integra en un ecosistema de microservicios desplegado como aplicación web pública en <https://uniandes-maia-g2.duckdns.org>, ejecutándose sobre una instancia AWS EC2 g4dn.xlarge (GPU NVIDIA T4 de 16 GB VRAM, 16 GB RAM, Amazon Linux 2023, Python 3.11). El backend, implementado en FastAPI con servidor uvicorn, orquesta la inferencia secuencial de T1 (segmentación retórica) y T2 (detección de contribuciones) con preprocesamiento dinámico de desacoplamiento léxico. El frontend ofrece visualización por códigos de color para las siete categorías retóricas y resaltado dinámico de los fragmentos identificados como contribuciones, permitiendo al usuario seleccionar dinámicamente entre tres familias de modelos: (i) un heurístico léxico-posicional empleado como fallback silencioso cuando no hay pesos disponibles, (ii) SciBETO-large fine-tuned ejecutado localmente en GPU, y (iii) grandes modelos de lenguaje —Llama 3.1 8B Instruct con cuantización a 4 bits y GPT-4o-mini vía API—, disponibles en modalidades zero-shot y few-shot ($k=14$ en T1). El acceso se expone tras nginx como proxy inverso, con cifrado HTTPS gestionado por Let's Encrypt y arranque persistente configurado como servicio systemd.

4. Resultados

Para la evaluación del desempeño se utilizaron métricas estándar de clasificación multiclase: Accuracy, F1-Macro (mismo peso a todas las categorías, métrica principal) y F1-Micro (pondera por frecuencia de clase). El F1-Macro se estableció como la métrica principal debido a su robustez para evaluar el rendimiento en clases minoritarias, pero críticamente ambiguas como DISC y LIM.

4.1. Tarea 1 – Segmentación Retórica

La evaluación se realizó sobre el conjunto de prueba Gold (anotado y validado manualmente). La Tabla 2 resume el desempeño global de las tres arquitecturas bajo las diferentes estrategias de inferencia y aprendizaje evaluadas.

Tabla 2. Resultados comparativos en la Segmentación Retórica. SciBETO fine-tuning vs. LLMs sobre el Gold Test Set (etiquetado manualmente). Métrica principal: F1 Macro.

Modelo	Estrategia	Accuracy	F1 Macro	F1 Micro
SciBETO-large	Fine-tuning	0.401	0.400	0.401
Llama 3.1 8B-Instruct	Zero-shot	0.279	0.234	0.279
Llama 3.1 8B-Instruct	Few-shot ($k=7$)	0.296	0.249	0.297
Llama 3.1 8B-Instruct	Few-shot ($k=14$)	0.355	0.322	0.355
GPT-4o-mini	Zero-shot	0.471	0.447	0.471
GPT-4o-mini	Few-shot ($k=7$)	0.435	0.394	0.435
GPT-4o-mini	Few-shot ($k=14$)	0.446	0.414	0.446

Como se detalla en la Tabla 2, el modelo comercial GPT-4o-mini alcanzó el mejor desempeño general bajo la estrategia zero-shot, registrando un `f1_macro` de 0.447 y una exactitud (Accuracy) de 0.471. Por su parte, SciBETO-large ajustado mediante fine-tuning se consolidó como la segunda arquitectura más competitiva

con un $f1_macro$ de 0.400. En contraste, el modelo de pesos abiertos Llama 3.1 8B exhibió un rendimiento inicialmente rezagado, marcando su piso técnico en la evaluación zero-shot con un $f1_macro$ de 0.234.

Los resultados también revelan un comportamiento diferente frente a las estrategias de provisión de contexto (*prompting*). Mientras que Llama 3.1 8B se benefició significativamente de la inyección de conocimiento empírico, escalando casi 9 puntos porcentuales hasta un F1 Macro de 0.322 al utilizar 14 ejemplos (*few-shot*), el rendimiento de GPT-4o-mini sufrió una degradación bajo la misma estrategia, cayendo a 0.414. Este fenómeno sugiere que, para LLMs altamente parametrizados y alineados, la imposición de ejemplos estáticos puede empeorar su robusta capacidad de generalización semántica *zero-shot*, introduciendo un sesgo hacia la sintaxis del *prompt* en detrimento del texto a evaluar.

A pesar de las variaciones en estrategias, la estabilización de las métricas en un techo generalizado (rango de 0.23 a 0.44) corrobora que la complejidad de la tarea reside en su naturaleza y no en deficiencias de los modelos. La retórica científica en español presenta fronteras difusas que generan ambigüedad incluso para los anotadores humanos que consolidaron el *Gold Set*.

4.1.1. Impacto del preprocesamiento

El uso de heurísticas para el filtrado inicial resultó fundamental en la limpieza del corpus de entrenamiento. Descartar documentos sin estructura formal aparente, tales como blogs, entrevistas, o reportes de divulgación, redujo significativamente el ruido semántico. Asimismo, la aplicación de reglas para excluir tablas, figuras y referencias mejoró la calidad del fragmento extraído, evitando artefactos que degradan la capacidad de aprendizaje del modelo. Aunque estas implementaciones mejoraron la calidad de los datos, los resultados sugieren que el desarrollo de reglas de extracción aún más finas podría mitigar el sesgo residual en el aprendizaje.

4.1.2. Impacto de la Longitud del Fragmento y Ventana de Contexto en un Encoder

Durante la experimentación, se identificó un fenómeno crítico relacionado con la ventana de contexto. Las primeras iteraciones, que utilizaron segmentos de hasta 1.000 palabras, arrojaron métricas deficientes ($f1_macro$ entre 0.20 y 0.25). Esto se atribuye principalmente a la restricción arquitectónica de SciBETO (basado en RoBERTa), cuya ventana máxima es de 512 tokens. Fragmentos excesivamente largos sufrían truncamiento, perdiendo la señal retórica esencial.

Al ajustar la extracción a fragmentos de entre 450 y 750 palabras, se redujo la superposición de categorías y se optimizó el uso del límite de tokens, permitiendo que el $f1_macro$ ascendiera a 0.40. Este hallazgo empírico confirma que la segmentación retórica no es una tarea puramente léxica, sino estructural: el modelo necesita la 'periferia' del texto para inferir la función discursiva de un fragmento.

Sin embargo, persiste un sesgo de distribución entre los conjuntos de datos. Mientras el modelo fue entrenado con bloques extensos, la mediana de longitud del conjunto de prueba manual ronda las 250 palabras (con variaciones extremas: DISC y LIM promedian ~65 palabras, frente a las ~580 de BACK). Esta disparidad provoca que el modelo tienda a sesgar sus predicciones hacia las categorías cuya longitud estructural se asemeja más a los datos de entrenamiento (Domain Shift).

4.1.3. Análisis de Errores e Inter-categorías en la tarea 1

Para comprender el comportamiento del modelo a nivel de clase, se analizó la matriz de confusión de las predicciones de SciBETO sobre el conjunto de prueba, contrastándola con los mejores resultados de los LLMs evaluados (ver Figura 1).




Figura 1. Matrices de confusión T1 para los mejores modelos de SciBETO (izquierda), Llama3.1 (centro), y GPT-4o (derecha).

A diferencia de modelos sin regularización léxica que tienden a colapsar sus predicciones en una sola clase mayoritaria, la matriz actual de SciBETO exhibe una distribución balanceada y una diagonal principal consistente. El análisis cualitativo revela los siguientes patrones discursivos:

- **Rendimiento destacado en METH y LIM (SciBETO):** La categoría de Metodología (METH) presentó el mejor equilibrio global (F1 de 0.52), impulsado por un léxico procedimental altamente distintivo. Sorprendentemente, la categoría de Limitaciones (LIM) obtuvo la tasa de recuperación (Recall) más alta del modelo (0.58), logrando identificar correctamente 116 de 200 fragmentos. Esto indica que el modelo es altamente eficaz capturando estructuras sintácticas de concesión o restricción (ej. "sin embargo", "no fue posible", "tamaño de la muestra"), incluso cuando se presentan en textos cortos.
- **La frontera INTRO–BACK:** Se observó una notable confusión direccional donde 51 fragmentos de Introducción (INTRO) fueron clasificados erróneamente como Antecedentes (BACK). Este solapamiento es coherente con la estructura tradicional del artículo científico, donde la introducción frecuentemente enmarca el problema mediante una revisión preliminar de la literatura.
- **Conflicto (RES–DISC–CONC):** El mayor desafío del modelo de SciBETO se concentra en las etapas finales del documento. La categoría de Discusión (DISC) registró el menor desempeño general (F1 de 0.29), dispersando sus predicciones hacia LIM (49 casos) y Conclusiones (CONC, 46 casos). De igual manera, 44 fragmentos de Resultados (RES) fueron etiquetados como CONC.

Comportamiento contrastante de los LLMs: Al observar el desempeño de los modelos de lenguaje de gran escala, se evidencian sesgos predictivos marcadamente distintos. En el caso de **Llama 3.1 8B (Few-shot)**, la matriz revela un colapso sistémico hacia la categoría de Antecedentes (BACK). Esta clase actuó como un "sumidero" semántico, absorbiendo masivamente predicciones de todas las demás categorías (por ejemplo, 100 casos de LIM y 93 de RES fueron clasificados erróneamente como BACK). Esto explica su bajo puntaje global: aunque detecta la introducción, fracasa en aislar la retórica de secciones especializadas.

Por otro lado, **GPT-4o-mini (Zero-shot)** exhibe una precisión excepcional en las secciones estructurales iniciales (INTRO, BACK y METH superan los 135 aciertos). Sin embargo, su capacidad analítica se degrada drásticamente en el bloque de cierre. Además de sufrir la misma confusión entre RES y DISC que SciBETO, GPT-4o-mini muestra una severa incapacidad para identificar Conclusiones (apenas 27 aciertos en CONC, dispersando los demás fragmentos hacia DISC e INTRO). Resulta notable que este LLM comercial pierda casi por completo la sensibilidad para detectar las Limitaciones (LIM, 55 aciertos) que el modelo especializado SciBETO sí logró aislar exitosamente (116 aciertos).

Esta última observación demuestra que el margen de error general no radica exclusivamente en la arquitectura del modelo, sino en la naturaleza borrosa de las fronteras retóricas en la escritura académica en español. La transición entre reportar un hallazgo empírico, interpretar su significado y declarar su conclusión puede hacerse débil. Al forzar al modelo de SciBETO a realizar una clasificación estrictamente mutuamente excluyente, se penalizan las oraciones híbridas. Los autores hispanohablantes frecuentemente discuten las

implicaciones de un resultado en el mismo párrafo en que lo reportan. Asimismo, el contraste entre SciBETO y GPT-4o-mini evidencia que el conocimiento paramétrico general de un LLM resuelve con éxito la macro-estructura del documento, pero carece de la sensibilidad requerida para desentrañar sutilezas de dominio específico sin un proceso de *fine-tuning*.

4.2. Tarea 2 – Detección de Contribuciones Científicas

4.2.1 Resultados cuantitativos

La Tabla 3 presenta los resultados de las seis configuraciones sobre el gold de T2. **SciBETO-large text-only** obtiene el mejor F1 Macro: 0.852 [IC 95%: 0.793-0.900], con AUC-ROC=0.946 y recall de la clase positiva de 0.963. Los intervalos de confianza al 95% se calcularon mediante bootstrap con 1.000 remuestras. Esto indica que el modelo detecta 78 de 81 contribuciones reales (solo 3 falsos negativos) con el umbral calibrado de 0.525, incurriendo en 22 falsos positivos de los 89 fragmentos negativos reales. La segunda configuración (SciBETO+contexto, F1=0.798) también muestra alto rendimiento, pero inferior al baseline text-only, resultado analizado en la Sección 5.3. Los LLMs muestran rendimiento inferior con una brecha mínima de 0.291 puntos de F1 Macro respecto al mejor modelo incluso con few-shot.

Tabla 3. Resultados de Tarea 2 sobre el gold (n=170). *=mejor configuración. IC 95% bootstrap n=1,000. F1 M.=F1 Macro, F1 ES_C.=F1 positivo, Rec.=Recall positivo.

Modelo / Configuración	F1 M.	F1 ES_C.	Prec.	Rec.	Acc. / AUC
SciBETO-large (text-only) *	0.852	0.868	0.808	0.938	0.864 / 0.946
SciBETO-large + contexto	0.821	0.840	0.738	0.975	0.823 / 0.925
Llama 3.1 8B (zero-shot)	0.393	0.093	0.800	0.049	0.541 / --
GPT-4o-mini (zero-shot)	0.423	0.168	0.571	0.099	0.535 / --
Llama 3.1 8B (few-shot, k=8)	0.561	0.439	0.643	0.333	0.594 / --
GPT-4o-mini (few-shot, k=8)	0.534	0.383	0.647	0.272	0.582 / --

La Figura 2 ilustra la comparación de cinco métricas para los seis modelos con barras de error del IC 95% sobre el F1 Macro. Destaca que el recall positivo de los LLMs zero-shot es casi nulo (Llama: 0.05; GPT: 0.09): estos modelos clasifican la mayoría de los fragmentos como NO_ES_CONTRIBUCION, reflejando un sesgo conservador ante la definición de contribución en ausencia de ejemplos calibradores.




Figura 2. Comparación de métricas para Tarea 2 sobre el gold (n=170, kappa=0.700). Barras de error en F1 Macro = IC 95% bootstrap. Elaboración propia.

4.2.2 Matrices de confusión

La Figura 3 muestra las matrices de confusión de los seis modelos evaluados. **SciBETO (text-only)** comete **18 falsos positivos y solo 5 falsos negativos**, lo que revela una política de predicción orientada hacia una **alta sensibilidad (recall)** para capturar la clase de interés. **SciBETO + contexto** exhibe un comportamiento similar, aunque incrementa los falsos positivos a 28, lo que explica la reducción en su F1-macro debido a una pérdida de precisión.

Por otro lado, los LLMs en configuración **zero-shot** concentran la práctica totalidad de sus errores en la fila de **falsos negativos (FN)**, evidenciando un sesgo severo hacia la clase mayoritaria: Llama clasifica erróneamente 77 de 81 contribuciones reales como "NO", mientras que GPT-4o-mini hace lo propio con 73 de 81 casos. Contrario a lo esperado, la introducción de **few-shot (k=8)** **no mitiga este colapso**, sino que profundiza el sesgo de omisión; Llama-fs eleva sus falsos negativos a 79 y GPT-fs a 78, consolidando una incapacidad generalizada de los LLMs para discriminar la clase "ES" bajo este esquema de *prompting*.




Figura 3. Matrices de confusión para los seis modelos en Tarea 2 (n=170 gold). Filas=etiqueta real, columnas=predicción. NO=NO_ES_CONTRIBUCION, ES=ES_CONTRIBUCION. Elaboración propia.

4.2.3 Efecto del contexto retórico (ablación)

El experimento de ablación del contexto retórico revela que incorporar el prefijo [SECCIÓN:X][POS:Y] al texto perjudica el rendimiento global en comparación con la versión *text-only* (Delta F1-Macro = -0.044, descendiendo de 0.865 a 0.821). La Tabla 4 muestra los resultados de dos ablaciones adicionales realizadas sobre el modelo SciBETO+contexto para evaluar el impacto real de esta señal.

Tabla 4. Ablaciones del prefijo contextual sobre el modelo SciBETO+contexto (n=170 gold).

Variante de entrada	F1 Macro	Delta F1	Interpretación
Prefijo real + texto real	0.821	--	Modelo de referencia (ctx)
Prefijo aleatorio + texto real	0.538	-0.283	El modelo usa el prefijo como señal
Prefijo real + texto vacío	0.323	-0.215	Sin texto aprox. aleatorio; texto imprescindible

La ablación A (prefijo aleatorio + texto real) reduce el F1-Macro en 0.283 puntos, confirmando que el modelo efectivamente aprendió a utilizar el prefijo como una señal discriminativa crítica. Por su parte, la ablación B (prefijo real + texto vacío) produce un F1-Macro de 0.323 (rendimiento inferior al azar para una tarea binaria equilibrada), lo que demuestra que el prefijo por sí solo no contiene suficiente información y que el texto es imprescindible para la clasificación. La interpretación conjunta es que SciBETO+contexto desarrolló una alta dependencia del prefijo como atajo contextual, haciéndolo vulnerable ante errores del componente T1 (encargado de extraer dicha estructura). Dado que T1 solo alcanza un F1-Macro de 0.37 (ver Sección 4.1), la señal del prefijo inyectada en la tubería es frecuentemente incorrecta. En contraste, SciBETO (text-only) se apoya exclusivamente en la semántica intrínseca del texto, quedando exento de este error en cascada. Este hallazgo tiene implicaciones directas para el diseño del sistema en producción: el pipeline T1 -> T2 con prefijo contextual no es recomendable dada la precisión limitada de T1.

4.2.4 Curvas ROC y Precision-Recall

Para evaluar la robustez de los clasificadores a través de diferentes umbrales de decisión, la Figura 4 ilustra las curvas ROC y de Precision-Recall (PR) para las dos variantes del modelo SciBETO sobre el conjunto

gold ($n=170$). La línea base discontinua en la curva PR (proporción de positivos = 0.476) confirma el balance del conjunto de prueba y ratifica que ambos modelos superan con creces el rendimiento estocástico.

En términos de discriminación global, el modelo **SciBETO (text-only)** obtuvo un AUC-ROC = 0.946, superando consistentemente a la variante **SciBETO + contexto** (AUC-ROC = 0.917) a lo largo de todo el espectro de operación. Este comportamiento se replica en el análisis de la curva Precision-Recall, donde el modelo *text-only* registró una precisión promedio de 0.915 frente al 0.889 de la versión con contexto. En este rango, la omisión del contexto retórico preserva una precisión significativamente superior, confirmando que la adición de variables contextuales externas degrada la estabilidad del clasificador.




Figura 4. Curvas ROC (izquierda) y Precision-Recall (derecha) para SciBETO text-only y SciBETO+contexto en Tarea 2 ($n=170$ gold). Elaboración propia.

5. Discusión

5.1. El Hallazgo Negativo del Contexto Retórico y su Interpretación

Los resultados revelan un patrón asimétrico entre T1 y T2. En T2, donde existe un corpus de entrenamiento de calidad suficiente (2,000 instancias silver con validación gold), SciBETO fine-tuned supera a GPT-4o-mini por un margen de 0.318 puntos de F1 Macro (0.852 vs. 0.534 en few-shot), y a Llama3.1 por 0.291 puntos. Este resultado valida el paradigma Data-Centric AI: invertir en la calidad del conjunto de datos y en el ajuste supervisado es más efectivo que escalar el tamaño del modelo generativo para esta tarea específica.

Sin embargo, en T1, GPT-4o-mini supera a SciBETO fine-tuned en 0.047 puntos de F1 Macro (0.447 vs. 0.400). Este resultado indica que el corpus de entrenamiento de T1, aunque 5 veces mayor en instancias que el de T2, no es suficientemente informativo para que el encoder aprenda a discriminar las siete categorías retórico-funcionales de forma robusta. Una hipótesis es que las etiquetas de T1 tienen mayor ruido inter-anotador que las de T2, o que la frontera entre categorías adyacentes es genuinamente ambigua en muchos fragmentos del corpus. La capacidad de GPT-4o-mini de aprovechar su pre-entrenamiento sobre texto académico multi-idioma puede compensar esta ambigüedad.

5.2. La Paradoja del Contexto y el Techo de Semántico (Tarea 1)

El hallazgo más relevante de la Tarea 1 fue la sensibilidad crítica de los modelos basados en arquitectura encoder frente a la longitud del fragmento y la presencia de anclas léxicas. La mejora sustancial en el f1-macro tras acercar las distribuciones de los conjuntos de entrenamiento y prueba, confirma que el análisis retórico en el español científico no es una tarea local, sino **estructural**: el modelo requiere de la periferia del texto para desambiguar la intención comunicativa.

Sin embargo, a pesar del ajuste del contexto y la aplicación de técnicas de regularización léxica (*Soft Masking*), las métricas globales se estancaron en un rango moderado (f1-macro de 0.40). Esto sugiere la existencia de un "techo de cristal" impuesto por dos factores convergentes:

1. **La brecha entre Heurísticas y Juicio Humano:** Existe una discrepancia intrínseca entre la señal de entrenamiento (*Silver Labels*), generada mediante expresiones regulares que asumen fronteras discursivas nítidas, y el conjunto de evaluación (*Gold Standard*), que refleja la variabilidad y riqueza del lenguaje humano natural.
2. **La Naturaleza de la Tarea:** El límite de generalización del modelo no obedece a una falta de comprensión semántica, sino a la imposición de una tarea de clasificación mutuamente excluyente sobre un texto que es fundamentalmente multilabel. Como evidenció la matriz de confusión, los autores hispanohablantes frecuentemente entrelazan el reporte de resultados empíricos (RES) con su interpretación teórica (DISC) o conclusiones preliminares (CONC) dentro de un mismo párrafo.

En consecuencia, el "techo de cristal" no es solo un artefacto de la calidad de los datos, sino un reflejo de la naturaleza del dominio. Penalizar a un modelo por clasificar como "Discusión" un fragmento de "Resultados" que contiene un componente interpretativo subraya la necesidad de redefinir la segmentación retórica: no como la asignación de categorías aisladas, sino la identificación de múltiples categorías retóricas que coexisten. Esto último justifica plenamente la aproximación transversal implementada en la Tarea 2 para la detección de contribuciones.

5.3. Colapso de los LLMs y Umbral de Ambigüedad Humana (Tarea 2)

El colapso de Llama 3.1 8B y GPT-4o-mini hacia la clase negativa en Tarea 2 (recall ES_CONTRIBUCION de 0.05 y 0.10 respectivamente) evidencia que los LLMs zero-shot adoptan una estrategia conservadora que minimiza falsos positivos a expensas de masivos falsos negativos. Este comportamiento es consistente con la tendencia documentada en la literatura de que los LLMs, sin ejemplos de calibración en dominio específico, tienden a predicciones conservadoras en tareas de clasificación binaria con definiciones operativas muy específicas. El análisis de los 30 fragmentos ambiguos (sin consenso interanotador, κ no calculable) revela que incluso los humanos discrepan principalmente en fragmentos de DISC con alusiones comparativas, confirmando que el límite superior teórico para cualquier modelo automático en esta tarea es inferior al 100%.

5.4. Fortalezas, Limitaciones y Decisiones de Diseño

La principal fortaleza del sistema es la robustez del protocolo de evaluación: el Gold Test Set de Tarea 2 ($\kappa = 0.70$) garantiza que las métricas reportadas reflejan el rendimiento real sobre datos de alta confiabilidad. La separación de las contribuciones como tarea binaria independiente (esquema 7+1) resultó ser un acierto arquitectónico que evita la sobrecomplejidad del esquema de 8 clases. Como limitaciones, destacan: (i) la dependencia de la calidad de extracción de PDF, donde el ruido residual actúa como entropía adicional; (ii) el techo de cristal de las Silver Labels en Tarea 1; y (iii) la ausencia de resultados completos few-shot para los LLMs, que podrían mejorar significativamente el rendimiento de estas arquitecturas.

5.5 Implicaciones prácticas para sistemas de producción

Desde la perspectiva operacional, SciBETO text-only es la configuración recomendada para despliegue: mayor F1 Macro, cero costo de API, latencia despreciable sobre GPU local y privacidad total de los datos. En comparación, GPT-4o-mini incurre en costos de ~\$0.015 USD por 170 fragmentos (\$0.088 por 1,000) y expone los textos al proveedor externo. Llama 3.1 8B es el modelo que más recursos computacionales consume, con pesos que se descargan por API de ~16,5GiB, rinde en GPU ~0.22 s/fragmentos (~3.6 min para 1,000 fragmentos), con cero costo de API y datos en servidor local,

6. Conclusiones y Trabajo Futuro

6.1. Hallazgos Principales

Este proyecto aportó evidencia empírica sobre la complejidad inherente al análisis automático de documentos científicos en español, subrayando que la eficacia de los sistemas de IA en dominios especializados depende de la integración armoniosa entre arquitectura del modelo y curaduría de datos:

- En la Tarea 1 (Segmentación Retórica), el modelo comercial de escala masiva GPT-4o-mini (*zero-shot*) alcanzó el límite superior con un F1 Macro de 0.447. Sin embargo, el *encoder* especializado SciBETO-large (0.400) se consolidó como la arquitectura de pesos abiertos más robusta, superando significativamente a Llama 3.1 8B (0.322) y demostrando una sensibilidad cualitativa superior para aislar categorías minoritarias como las Limitaciones. Por el contrario, en la Tarea 2, SciBETO-large supera de manera contundente a los LLMs, alcanzando un F1 Macro de 0.852 frente a Llama 3.1 8B (0.39) y GPT-4o-mini (0.42).
- La alineación de la ventana de contexto es uno de los factores técnicos más determinantes en la segmentación retórica. Reducir la extensión de los fragmentos en el conjunto de entrenamiento, pasando de bloques de hasta 1.000 palabras a ventanas más focalizadas de entre 450 y 750 palabras, fue crucial para optimizar el límite estricto de 512 *tokens* de SciBETO. Esta reducción mitigó el truncamiento de información esencial y disminuyó la superposición de categorías, elevando el F1 Macro a 0.400. Esto confirma que el análisis del discurso en español no es una tarea puramente léxica, sino estructural, requiriendo un balance que provea suficiente periferia del texto sin diluir la señal retórica principal.
- El prefijo de contexto retórico daña el desempeño de T2 ($\Delta = -0.044$), hallazgo negativo que evidencia que la distribución mixta de contribuciones entre secciones neutraliza el poder discriminativo de la etiqueta retórica.
- El acuerdo interanotador ($\kappa = 0.70$) establece un límite superior teórico para el desempeño automático: el 15% de los casos es inherentemente ambiguo incluso para humanos expertos.
- El esquema 7+1 (retórica + contribuciones como tareas independientes) refleja con mayor fidelidad la realidad discursiva que un esquema de 8 clases mutuamente excluyentes.

6.2. Trabajo Futuro

Para superar las limitaciones identificadas se proponen las siguientes líneas de investigación: (i) iteración del motor de Silver Labels con análisis de errores para refinar la cobertura de categorías ambiguas (RES, DISC, LIM); (ii) ampliación del Gold Standard con múltiples anotadores y métricas formales de acuerdo (Fleiss' κ); (iii) evaluación completa del prompting few-shot para los LLMs en Tarea 2, incluyendo análisis de sensibilidad al número de ejemplos y al orden de presentación; (iv) exploración de técnicas de fine-tuning eficiente (LoRA/QLoRA) sobre modelos de mayor escala para evaluar el impacto del escalado de parámetros; (v) incorporación de características estructurales —posición relativa, tipo de documento, longitud normalizada— como entradas adicionales más allá del prefijo textual; y (vi) estudio del impacto de las estrategias de prefiltrado de documentos sobre la calidad final de los modelos entrenados.

7. Referencias

- [1] R. Johnson, A. Watkinson, and M. Mabe, "The STM report: An overview of scientific and scholarly publishing," STM Association, 5th ed., 2018.
- [2] J. Devlin, M. W. Chang, K. Lee y K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in Proc. NAACL-HLT, Minneapolis, MN, 2019, pp. 4171–4186.
- [3] I. Beltagy, K. Lo y W. Cohan, "SciBERT: A Pretrained Language Model for Scientific Text," in Proc. EMNLP, Hong Kong, 2019, pp. 3615–3620.
- [4] J. Cañete, G. Chaperon, R. Fuentes, J. H. Ho, H. Kang y J. Pérez, "Spanish Pre-trained BERT Model and Evaluation Data," in PML4DC at ICLR, 2020.
- [5] Flaglab, "SciBETO-large: Scientific Spanish BERT," Hugging Face, 2024. [En línea]. Disponible en: <https://huggingface.co/Flaglab/SciBETO-large>
- [6] J. M. Swales, Genre Analysis: English in Academic and Research Settings. Cambridge, UK: Cambridge University Press, 1990.
- [7] Meta AI, "The Llama 3 Herd of Models," arXiv preprint arXiv:2407.21783, 2024.
- [8] OpenAI, "GPT-4 Technical Report," arXiv preprint arXiv:2303.08774, 2023.